

LAPORAN PROYEK AKHIR

Mata Kuliah Pembelajaran Mesin Semester Genap 2025/2026

OPTIMASI TEKNIK MACHINE LEARNING DALAM KLASIFIKASI KELULUSAN MAHASISWA

Implementasi dan Perbandingan KNN, Naive Bayes, dan Support Vector Machine



Ahnaf Fawwaz Arjanta

NIM: A11.2024.15835

Dosen Pengampu: Junta Zeniarja, M.Kom

Program Studi Teknik Informatika

Fakultas Ilmu Komputer

UNIVERSITAS DIAN NUSWANTORO

SEMARANG 2026

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Kelulusan tepat waktu merupakan salah satu indikator kualitas yang paling sering dijadikan acuan dalam penilaian akreditasi program studi di perguruan tinggi Indonesia. Ketika seorang mahasiswa mengalami keterlambatan studi atau bahkan drop out, dampaknya tidak hanya dirasakan secara personal oleh mahasiswa dan keluarganya, tetapi juga memengaruhi reputasi institusi secara keseluruhan. Permasalahan ini semakin kompleks mengingat jumlah mahasiswa yang besar membuat proses pemantauan individual menjadi sangat sulit dilakukan secara manual oleh dosen wali atau program studi.

Pendekatan konvensional seperti evaluasi semester dan bimbingan akademik memang telah lama diterapkan, namun sifatnya cenderung reaktif. Artinya, intervensi baru dilakukan ketika mahasiswa sudah menunjukkan tanda-tanda kesulitan yang terlihat secara nyata, seperti nilai yang anjlok atau ketidakhadiran yang tinggi. Dalam banyak kasus, saat intervensi dilakukan, kondisi akademik mahasiswa sudah cukup parah dan sulit diperbaiki dalam waktu singkat. Dibutuhkan pendekatan yang lebih proaktif dan berbasis data agar program studi bisa mengambil langkah lebih awal sebelum kondisi mahasiswa memburuk.

Machine learning menawarkan solusi yang menjanjikan untuk permasalahan ini. Dengan memanfaatkan data historis akademik dan sosial-finansial mahasiswa, model prediktif dapat dibangun untuk mengidentifikasi pola-pola yang mengindikasikan risiko keterlambatan studi sejak dini. Dataset yang digunakan dalam project ini adalah UCI Predict Students' Dropout and Academic Success yang dipublikasikan oleh Realinho et al. (2022), mencakup 4.424 data mahasiswa dengan 36 fitur yang meliputi data demografis, akademik, dan kondisi sosial-ekonomi. Dataset ini dipilih karena kelengkapan fiturnya dan distribusi kelas yang hampir seimbang sempurna (49,93% vs 50,07%), sehingga eksperimen dapat berjalan tanpa bias besar akibat imbalance.

Project ini membangun sistem bernama EduPredict yang tidak hanya berhenti pada pembuatan model prediksi, melainkan juga mengemas model tersebut ke dalam aplikasi web yang dapat digunakan langsung oleh dosen wali dan staf akademik. Tiga algoritma klasifikasi yang berbeda karakter, yaitu K-Nearest Neighbors (KNN), Naive Bayes, dan Support Vector Machine (SVM), dibandingkan secara sistematis mulai dari baseline hingga versi yang dioptimasi menggunakan teknik hyperparameter tuning dan feature selection.

1.2 Tujuan Project

Project ini memiliki tiga tujuan utama yang saling berkaitan. Pertama, membangun dan membandingkan model baseline KNN, Naive Bayes, dan SVM menggunakan pipeline yang konsisten dan reproducible, sehingga perbandingan antar model dapat dilakukan secara adil. Kedua, menerapkan strategi optimasi yang mencakup GridSearchCV, RandomizedSearchCV, stratified k-fold cross validation, dan feature selection berbasis mutual information untuk meningkatkan performa model dari titik baseline. Ketiga, mengembangkan aplikasi web EduPredict yang mengintegrasikan Streamlit sebagai frontend dan FastAPI sebagai backend REST API, sehingga model dapat diakses secara interaktif oleh pengguna non-teknis seperti dosen wali.

1.3 Relevansi OBE

Project ini dirancang untuk memenuhi capaian pembelajaran yang ditetapkan dalam Rencana Pembelajaran Semester (RPS) Mata Kuliah Pembelajaran Mesin. Secara spesifik, project ini mendukung Sub-CPMK 81.2 dan 81.3 yang berkaitan dengan implementasi dan

evaluasi algoritma klasifikasi, serta Sub-CPMK 101.1 dan 101.2 yang mencakup pengembangan sistem berbasis machine learning. Pada level Capaian Pembelajaran Lulusan, project ini berkontribusi pada CPL8 (kompetensi implementasi komputasi) dan CPL10 (kemampuan mengembangkan sistem cerdas yang memenuhi kebutuhan pengguna). Integrasi antara notebook eksperimen, API, dan aplikasi web mencerminkan pendekatan end-to-end yang menjadi target kompetensi program studi.

BAB 2 STUDI LITERATUR

2.1 Mini-Review Paper Utama (2024–2026)

Bagian ini merangkum lima paper terbaru yang menjadi landasan metodologis project ini. Pemilihan paper didasarkan pada relevansi topik (prediksi kelulusan atau performa akademik), metode yang digunakan (KNN, Naive Bayes, SVM, atau teknik optimasi serupa), dan kemutakhiran publikasi (2024–2026). Setiap paper dikaji dari sisi metode, dataset, hasil, dan kontribusi spesifiknya terhadap desain eksperimen project ini.

Tabel 2.1 State-of-the-Art Prediksi Kelulusan Mahasiswa

Penulis	Tahun	Jurnal	Metode & Dataset	Hasil	Relevansi
Al Hakim et al.	2026	JUTIF	XGBoost, AdaBoost, RF + Grid/RandomSearch UCI 3.630 baris	Acc 91,18%	Basis Grid vs Random Search; scoring F1; k-fold CV
Turkmenbayev et al.	2025	Frontiers Educ.	KNN, NB, SVM Dataset teknik	Acc 89,1%	Review KNN/NB/SVM; validasi pemilihan algoritma
Malik et al.	2025	Sci. Reports	Feature selection + clf Multi-dataset	F1 88,7%	Mutual information; SelectKBest pipeline
Pelima et al.	2024	IEEE Access	SVM, KNN Dataset kelulusan PT	Acc 87,4%	Fitur semester awal sebagai prediktor terkuat
Setiawan et al.	2026	ERIES J.	Multi-class clf Multi-institusi	Balanced Acc	Macro-F1 sebagai metrik utama; stratified CV

2.2 Sintesis Metode Optimasi

Dari kelima paper di atas, lima strategi optimasi dapat disintesis dan diadaptasi ke dalam project ini. Pertama, hyperparameter tuning menggunakan GridSearchCV dan RandomizedSearchCV dengan scoring macro-F1 sebagaimana diterapkan oleh Al Hakim et al. (2026). GridSearchCV cocok untuk ruang pencarian yang kecil karena melakukan evaluasi exhaustive pada setiap kombinasi parameter, sementara RandomizedSearchCV lebih efisien untuk ruang yang lebih besar karena hanya mengevaluasi sejumlah kombinasi secara acak.

Kedua, penggunaan stratified 5-fold cross validation untuk mendapatkan estimasi performa yang lebih robust dan tidak bergantung pada satu pembagian data tertentu. Ketiga, feature selection berbasis mutual information menggunakan SelectKBest yang diintegrasikan langsung ke dalam pipeline sklearn, sehingga feature selection menjadi bagian dari proses tuning dan tidak menimbulkan data leakage. Keempat, penanganan class imbalance melalui parameter `class_weight='balanced'` pada SVM sebagaimana disarankan oleh Setiawan et al. (2026). Kelima, evaluasi multi-metrik yang mencakup Accuracy, Precision, Recall, Macro-

F1, dan Balanced Accuracy untuk mendapatkan gambaran performa yang komprehensif dan tidak bias terhadap kelas mayoritas.

Pilihan untuk menggunakan macro-F1 sebagai metrik utama didasarkan pada konsensus dari literatur yang dikaji. Macro-F1 menghitung F1-score secara terpisah untuk setiap kelas lalu mengambil rata-rata tanpa pembobotan, sehingga performa pada kelas minoritas mendapat porsi yang sama pentingnya dengan kelas mayoritas. Ini penting dalam konteks prediksi kelulusan di mana kesalahan mendeteksi mahasiswa berisiko (false negative) memiliki konsekuensi nyata.

BAB 3 DATASET DAN DATA DICTIONARY

3.1 Sumber dan Karakteristik Dataset

Dataset yang digunakan dalam project ini adalah UCI Predict Students' Dropout and Academic Success yang dipublikasikan oleh Realinho et al. (2022) melalui UCI Machine Learning Repository. Dataset ini berisi data dari sebuah institusi pendidikan tinggi di Portugal dan mencakup informasi mahasiswa yang terdaftar pada berbagai program sarjana. Setiap baris merepresentasikan satu mahasiswa dengan 36 fitur prediktor dan satu kolom target yang awalnya bersifat multiclass (Graduate, Dropout, Enrolled).

Untuk keperluan project ini, target multiclass disederhanakan menjadi klasifikasi biner: Graduate (lulus) dipetakan ke kelas 1, sementara Dropout dan Enrolled (belum lulus pada akhir periode observasi) dipetakan ke kelas 0. Hasil pemetaan ini menghasilkan distribusi yang sangat seimbang, yaitu 2.209 sampel positif (49,93%) dan 2.215 sampel negatif (50,07%). Keseimbangan ini merupakan kondisi ideal yang jarang ditemukan pada dataset dunia nyata dan mempermudah eksperimen karena model tidak perlu berjuang melawan bias kelas dominan.

Tabel 3.1 Kelompok Fitur Dataset

Kelompok	Fitur Utama	Keterangan
Demografis (6 fitur)	Marital status, Age, Gender, Displaced, International	Profil pribadi saat mendaftar; seluruh numerik/biner
Akademik Pra-PT (7 fitur)	Application mode, Admission grade, Previous qualification	Jalur masuk; nilai skala 95-190
Sosio-Ekonomi (8 fitur)	Mother/Father qualification & occupation, Scholarship, Debtor, Tuition	Latar keluarga; finansial mahasiswa
Akademik Sem 1 & 2 (12 fitur)	CU enrolled, approved, evaluations, grade (per semester)	Performa 2 semester; grade skala 0-18,875
Makroekonomi (3 fitur)	Unemployment rate, Inflation rate, GDP	Kondisi ekonomi saat studi

Dari 36 fitur yang tersedia, fitur-fitur akademik semester 1 dan 2 terbukti menjadi prediktor terkuat dalam eksperimen ini. Hal ini konsisten dengan temuan Pelima et al. (2024) yang menyebutkan bahwa performa akademik pada semester awal memiliki daya prediksi tertinggi terhadap kelulusan. Fitur Tuition fees up to date (status pembayaran UKT) juga menjadi kontributor penting, menunjukkan bahwa kondisi finansial mahasiswa berkorelasi signifikan dengan probabilitas kelulusan tepat waktu.

3.2 Etika dan Privasi Data

Penggunaan data mahasiswa dalam penelitian machine learning memerlukan perhatian khusus terhadap aspek etika dan privasi. Dataset UCI yang digunakan telah melalui proses anonimisasi oleh penerbit, sehingga identitas mahasiswa secara langsung tidak dapat

direkonstruksi dari data yang tersedia. Tidak ada nama, nomor identitas, atau informasi kontak yang terdapat dalam dataset.

Dalam konteks penggunaan sistem EduPredict, perlu ditegaskan bahwa model prediksi ini dirancang sebagai alat bantu pengambilan keputusan (decision support tool), bukan sebagai penentu final status akademik mahasiswa. Artinya, output prediksi model harus selalu dikontekstualisasikan dengan informasi kualitatif yang diketahui oleh dosen wali, seperti kondisi keluarga, motivasi, dan kendala personal yang tidak tercermin dalam data. Fitur-fitur sensitif seperti status debitur (debtor) dan penerimaan beasiswa digunakan semata-mata untuk tujuan prediksi akademik, bukan untuk tujuan profiling administratif atau diskriminasi.

BAB 4 AUDIT DATA DAN PREPROCESSING

4.1 Hasil Audit Data

Sebelum data digunakan untuk pelatihan model, dilakukan audit komprehensif untuk memastikan kualitas data dan mendeteksi potensi masalah yang dapat mengganggu proses pelatihan atau validitas hasil eksperimen. Audit ini mencakup pemeriksaan dimensi, missing values, duplikat, tipe data, distribusi target, outlier, dan potensi data leakage.

Tabel 4.1 Ringkasan Audit Dataset

Aspek	Temuan	Tindakan
Dimensi	4.424 baris x 37 kolom	Memenuhi syarat (>300 baris, >8 fitur)
Missing values & Duplikat	0 (nihil)	Tidak diperlukan imputasi/penghapusan
Tipe data	Seluruh numerik (int & float)	Tidak diperlukan encoding tambahan
Distribusi target biner	49,93% vs 50,07%	Stratified split; class_weight SVM
Outlier	Ada pada kode kategorikal	Tidak dihapus; kode kategori valid
Potensi data leakage	Tidak ditemukan	Scaler hanya di-fit pada train set

Hasil audit menunjukkan bahwa dataset ini tergolong bersih dan siap digunakan tanpa memerlukan langkah data cleaning yang intensif. Ketiadaan missing value merupakan keunggulan dataset ini dibanding banyak dataset pendidikan dunia nyata yang seringkali memiliki data tidak lengkap. Nilai-nilai yang tampak seperti outlier pada beberapa fitur kategorik sebenarnya merupakan kode valid sesuai data dictionary yang disertakan penerbit, sehingga tidak perlu dihapus.

4.2 Pipeline Preprocessing

Pipeline preprocessing dirancang untuk menjamin konsistensi dan mencegah data leakage yang dapat menghasilkan estimasi performa yang terlalu optimis. Lima tahap dilakukan secara berurutan:

Tahap 1 Drop Duplicates. Pemeriksaan dan penghapusan data duplikat. Pada dataset ini tidak ditemukan duplikat sehingga tidak ada baris yang dihapus.

Tahap 2 Binarisasi Target. Kolom target yang awalnya multiclass (Graduate, Dropout, Enrolled) dikonversi menjadi biner: Graduate=1, sisanya=0. Ini mengubah problem dari klasifikasi tiga kelas menjadi klasifikasi biner yang lebih sesuai dengan kebutuhan early warning system.

Tahap 3 Pemisahan Fitur dan Target. Matriks fitur X (4.424 x 36) dan vektor target y (4.424) dipisahkan untuk persiapan split dan training.

Tahap 4 Stratified Train-Test Split 80:20. Dataset dibagi menjadi data latih (3.539 sampel) dan data uji (885 sampel) menggunakan stratified split dengan random_state=42. Parameter stratify=y memastikan proporsi kelas pada data latih dan uji sama dengan proporsi aslinya, sehingga evaluasi tidak terpengaruh distribusi yang tidak merata.

Tahap 5 StandardScaler. Normalisasi fitur menggunakan StandardScaler yang hanya di-fit pada data latih, kemudian diaplikasikan (transform) ke data latih maupun data uji. Urutan ini penting untuk mencegah data leakage, karena jika scaler di-fit pada seluruh data (termasuk data uji), model secara tidak langsung 'melihat' statistik data uji sebelum evaluasi. Normalisasi wajib dilakukan terutama untuk KNN dan SVM yang sangat sensitif terhadap perbedaan skala antar fitur.

BAB 5 DESAIN EKSPERIMEN

5.1 Konfigurasi Baseline dan Grid Hyperparameter

Setiap model dijalankan dalam dua tahap. Pertama, model baseline menggunakan parameter default dari scikit-learn tanpa optimasi apapun. Tujuannya adalah untuk mendapatkan titik referensi awal yang mencerminkan performa 'out of the box' masing-masing algoritma. Kedua, model optimized yang menggunakan pipeline sklearn berisi SelectKBest dan model target, kemudian di-tune menggunakan teknik pencarian hyperparameter yang sesuai dengan karakteristik ruang pencariannya.

Seluruh eksperimen ini diimplementasikan dalam notebook utama notebooks/graduation_optimization.ipynb yang mencakup Soal 01 hingga 05 secara berurutan, mulai dari eksplorasi data, preprocessing, training baseline, optimasi, hingga evaluasi akhir. Notebook ini dilengkapi output lengkap yang dapat diverifikasi ulang secara independen dengan menjalankan python src/train.py yang mengeksekusi pipeline yang sama secara non-interaktif.

Tabel 5.1 Parameter Baseline dan Ruang Pencarian Optimasi

Model	Metode	Parameter Baseline dan Ruang Pencarian Optimasi
KNN	GridSearchCV	Default: k=5, weights=uniform Grid: select__k:{15,20,36} n_neighbors:{3,5,7,9,11} weights:{uniform,distance}
Naive Bayes	GridSearchCV	Default: var_smoothing=1e-9 Grid: select__k:{15,20,36} var_smoothing:logspace(-9,-1,5) priors:{None,[0.5,0.5]}
SVM	RandomSearch n=20	Default: kernel=rbf, C=1 Dist: select__k:{15,20,36} C:{0.1,1,10} kernel:{rbf,linear} gamma:{scale,auto} class_weight:{balanced}

5.2 Strategi Optimasi

Pipeline sklearn yang menggabungkan SelectKBest(mutual_info_classif) dengan model target dipilih karena memiliki keunggulan penting: feature selection menjadi bagian dari proses cross-validation. Ini berarti pada setiap fold, fitur dipilih hanya berdasarkan informasi dari data training fold tersebut, tanpa 'melihat' data validation. Pendekatan ini mencegah selection bias yang dapat terjadi jika feature selection dilakukan di luar pipeline sebelum cross-validation dimulai.

Penggunaan macro-F1 sebagai scoring utama dipilih karena dataset, meski hampir seimbang, memiliki konteks asimetris: false negative (mahasiswa berisiko yang tidak terdeteksi) memiliki konsekuensi lebih besar daripada false positive. Macro-F1 memberikan bobot yang sama untuk performa pada kedua kelas sehingga model yang

secara konsisten baik di kedua kelas akan mendapat skor lebih tinggi daripada model yang sangat baik di satu kelas tapi buruk di kelas lain.

Pemilihan antara GridSearchCV dan RandomizedSearchCV untuk masing-masing model didasarkan pada ukuran ruang pencarian. KNN dan Naive Bayes memiliki ruang pencarian yang relatif kecil (masing-masing 30 dan 30 kombinasi), sehingga GridSearchCV yang exhaustive masih efisien. SVM memiliki ruang yang lebih besar dengan parameter kernel, C, gamma, dan class_weight yang bisa dikombinasikan, sehingga RandomizedSearchCV dengan 20 iterasi dipilih untuk efisiensi komputasi. StratifiedKFold(n_splits=5, shuffle=True, random_state=42) digunakan secara konsisten di semua model untuk memastikan komparabilitas hasil CV.

BAB 6 HASIL EKSPERIMEN

6.1 Perbandingan Baseline vs Optimized

Seluruh model dievaluasi pada test set yang sama (n=885) menggunakan metrik yang konsisten. Tabel berikut merangkum hasil lengkap untuk semua kombinasi model dan tahap optimasi. Kolom CV F1 menunjukkan rata-rata macro-F1 dari 5-fold cross validation pada data training, sementara kolom Accuracy hingga Balanced mencerminkan performa aktual pada test set yang belum pernah dilihat model selama training.

Tabel 6.1 Performa Lengkap pada Test Set (n=885)

Model & Tahap	CV F1	Accuracy	Precision	Recall	Macro-F1	Balanced Acc
KNN - Baseline	-	76,72%	77,45%	76,73%	76,57%	76,73%
KNN - Optimized	83,13%	80,90%	81,39%	80,91%	80,83%	80,91%
Naive Bayes - Baseline	-	73,22%	75,45%	73,24%	72,63%	73,24%
Naive Bayes - Optimized	75,32%	73,67%	77,71%	73,69%	72,69%	73,69%
SVM - Baseline *	-	82,15%	82,71%	82,15%	82,07%	82,15%
SVM - Optimized	84,96%	81,69%	82,07%	81,70%	81,64%	81,70%

* SVM Baseline dipilih sebagai model deployment: Macro-F1 82,07% tertinggi, stabil, konsisten

6.2 Confusion Matrix SVM Baseline

Confusion matrix memberikan gambaran lebih detail tentang bagaimana model SVM Baseline melakukan klasifikasi pada test set. Dari 885 sampel uji, model berhasil mengklasifikasikan dengan benar sebanyak 727 kasus (82,15%). Distribusi kesalahan hampir seimbang antara false positive dan false negative, menunjukkan model tidak bias ke salah satu kelas.

Tabel 6.2 Confusion Matrix SVM Baseline (Model Deployment)

	Prediksi: Tidak Lulus (0)	Prediksi: Lulus (1)
Aktual: Tidak Lulus (0)	TN = 363 (benar)	FP = 80 (salah)
Aktual: Lulus (1)	FN = 78 (salah)	TP = 364 (benar)

6.3 Analisis Kesalahan (Error Analysis)

Dari 885 sampel uji, SVM Baseline menghasilkan 158 prediksi salah. False Negative sebanyak 78 kasus (8,8%) berarti mahasiswa yang sebenarnya lulus diprediksi sebagai

berisiko. Dari perspektif operasional, ini relatif tidak berbahaya karena mahasiswa yang sebenarnya tidak berisiko akan mendapat perhatian berlebih, namun tidak mengalami kerugian nyata.

False Positive sebanyak 80 kasus (9,0%) lebih kritis secara operasional: mahasiswa yang sebenarnya berisiko justru tidak terdeteksi oleh sistem. Dalam konteks early warning system, kasus inilah yang paling penting untuk diminimalkan di pengembangan selanjutnya. Analisis terhadap pola kesalahan ini menunjukkan bahwa mayoritas kasus yang salah prediksi memiliki profil campuran, yaitu nilai IPS moderat di semester 1 dan 2 yang tidak secara tegas menunjukkan sinyal kelulusan atau risiko, disertai kondisi finansial yang tidak menentu.

Lima fitur dengan kontribusi mutual information tertinggi yang secara konsisten muncul dalam model optimal adalah: CU 2nd semester approved (jumlah mata kuliah yang lulus di semester 2), CU 1st semester approved (semester 1), CU 2nd semester grade (rata-rata nilai semester 2), Tuition fees up to date (status pembayaran UKT), dan CU 1st semester grade (rata-rata nilai semester 1). Dominasi fitur akademik semester awal ini sejalan dengan temuan Pelima et al. (2024) dan memberikan justifikasi kuat bahwa performa dua semester pertama adalah jendela prediksi yang paling informatif.

BAB 7 PEMBAHASAN

7.1 Model Terbaik dan Justifikasi Pemilihan

Pemilihan model untuk deployment memerlukan pertimbangan yang lebih dari sekadar melihat angka tertinggi dalam satu metrik. Empat kriteria digunakan secara bersamaan: (1) performa absolut pada test set menggunakan Macro-F1 sebagai metrik utama, (2) konsistensi antara skor CV dan skor test set sebagai indikator generalisasi, (3) ketersediaan predict_proba untuk output probabilistik pada antarmuka EduPredict, dan (4) besaran delta terhadap baseline sebagai bukti efektivitas optimasi.

Berdasarkan keempat kriteria tersebut, SVM Baseline dipilih sebagai model deployment. SVM Baseline mencapai Macro-F1 tertinggi secara absolut sebesar 82,07% di antara seluruh model yang diuji. Berbeda dengan KNN yang justru membutuhkan optimasi untuk meningkat signifikan, SVM sudah memberikan performa maksimalnya dengan konfigurasi default (kernel RBF, C=1). Ini menunjukkan bahwa hyperplane pemisah yang dihasilkan oleh SVM dengan parameter default sudah sangat sesuai dengan distribusi data akademik mahasiswa dalam dataset ini.

Satu hal menarik yang patut dicatat adalah bahwa SVM Optimized justru mengalami sedikit penurunan ke 81,64%, sementara CV F1-nya mencapai 84,96%. Gap antara CV dan test set ini mengindikasikan adanya sedikit overfitting terhadap fold training, kemungkinan akibat kombinasi SelectKBest dan parameter yang lebih ketat hasil RandomizedSearchCV dengan hanya 20 iterasi. Ini justru mengonfirmasi bahwa SVM Baseline adalah pilihan paling robust dan stabil untuk production deployment.

Tabel 7.1 Trade-off Ketiga Model pada Tahap Terbaik

Dimensi	SVM Baseline (dipilih)	KNN Optimized	NB Optimized
Macro-F1 Test	82,07%	80,83%	72,69%
CV Macro-F1	N/A (baseline)	83,13%	75,32%
Delta vs Baseline	Referensi	+4,26 pp	+0,06 pp
Kompleksitas inference	O(n features)	O(n data)	O(n features)
Interpretabilitas	Rendah (kernel RBF)	Sedang (jarak)	Tinggi (probabilistik)

predict_proba	Tersedia (probability=True)	Tersedia	Tersedia
Stabilitas (CV vs test)	Konsisten (baseline)	Konsisten	Konsisten

7.2 Analisis per Algoritma

SVM. Algoritma ini langsung menunjukkan performa terbaik bahkan tanpa optimasi. SVM bekerja dengan mencari hyperplane optimal yang memisahkan dua kelas di ruang fitur berdimensi tinggi. Karena dataset sudah ternormalisasi dengan StandardScaler dan distribusi kelasnya seimbang, kondisi ini sangat menguntungkan SVM. Kernel RBF default mampu menangkap hubungan non-linear antar fitur akademik yang tidak dapat dijelaskan oleh pemisah linear sederhana. Ini konsisten dengan temuan dari Turkmenbayev et al. (2025) yang juga mendapati SVM sebagai algoritma terbaik pada dataset performa mahasiswa teknik.

KNN. Algoritma ini memperlihatkan peningkatan terbesar dari proses optimasi: +4,26 pp dari baseline ke optimized. Dengan menemukan jumlah tetangga (k) dan skema pembobotan yang tepat melalui GridSearchCV, KNN berhasil mengurangi pengaruh noise dari tetangga yang terlalu jauh. Kelemahan utamanya adalah kompleksitas inferensi $O(n)$ yang artinya waktu prediksi meningkat linear seiring bertambahnya data training. Untuk skala UDINUS yang mungkin memiliki ribuan mahasiswa, ini perlu menjadi pertimbangan jika sistem diperluas ke seluruh institusi.

Naive Bayes. Peningkatan yang sangat marginal (+0,06 pp) mencerminkan keterbatasan fundamental algoritma ini pada dataset ini. Asumsi independensi kondisional antar fitur yang menjadi fondasi Naive Bayes tidak terpenuhi karena fitur-fitur akademik semester 1 dan 2 memiliki korelasi tinggi satu sama lain (mahasiswa yang mengambil banyak SKS di semester 1 cenderung juga mengambil banyak di semester 2). Meski demikian, Naive Bayes tetap berguna sebagai baseline tercepat dan paling ringan secara komputasi.

7.3 Implikasi Institusional

Dari perspektif implementasi di perguruan tinggi, sistem EduPredict menawarkan beberapa nilai tambah konkret. Pertama, kemampuan melakukan screening awal terhadap ribuan mahasiswa secara simultan di akhir semester 2, mengidentifikasi mereka yang memerlukan perhatian khusus dengan skor risiko terukur. Ini jauh lebih efisien daripada pendekatan manual yang bergantung pada penilaian subjektif dosen wali semata.

Kedua, model dapat diintegrasikan ke Sistem Informasi Akademik (SIKAD) universitas melalui REST API yang disediakan FastAPI, sehingga tidak memerlukan penggantian sistem yang sudah ada. Mode Microservices memungkinkan SIKAD eksternal untuk mengirimkan data mahasiswa via endpoint POST /predict dan menerima kembali prediksi lengkap dengan probabilitas dan analisis naratif dalam format JSON.

Ketiga, perlu ditekankan bahwa model ini adalah alat bantu decision support, bukan pengganti judgement manusia. Catatan integritas yang ditampilkan di bagian bawah halaman Prediksi pada aplikasi EduPredict secara eksplisit menyatakan bahwa prediksi diproses oleh FastAPI backend menggunakan predict_proba model tanpa manipulasi pakar, dan variabel makroekonomi menggunakan parameter baseline dataset untuk menjaga konsistensi ruang dimensi model. Transparansi ini penting untuk membangun kepercayaan pengguna terhadap sistem.

BAB 8 DESAIN APLIKASI EDUPREDICT

8.1 Arsitektur dan Tech Stack

EduPredict dirancang dengan arsitektur modular yang memisahkan tanggung jawab antara komponen secara jelas. Sistem mendukung dua mode operasi yang dapat dipilih sesuai kebutuhan: Mode Monolitik di mana Streamlit langsung memanggil model dari file joblib tanpa perlu backend terpisah, dan Mode Microservices di mana Streamlit berkomunikasi dengan FastAPI melalui HTTP request, memungkinkan integrasi dengan sistem eksternal.

Tabel 8.1 Tech Stack EduPredict

Layer / Kategori	Teknologi
Programming Language	Python 3.11
Machine Learning	scikit-learn
Data Processing	Pandas, NumPy
Visualization	Plotly, Matplotlib, Seaborn
Frontend Framework	Streamlit
REST API Framework	FastAPI
API Server	Uvicorn
Model Serialization	Joblib
Data Validation	Pydantic
Deployment Engine	Docker

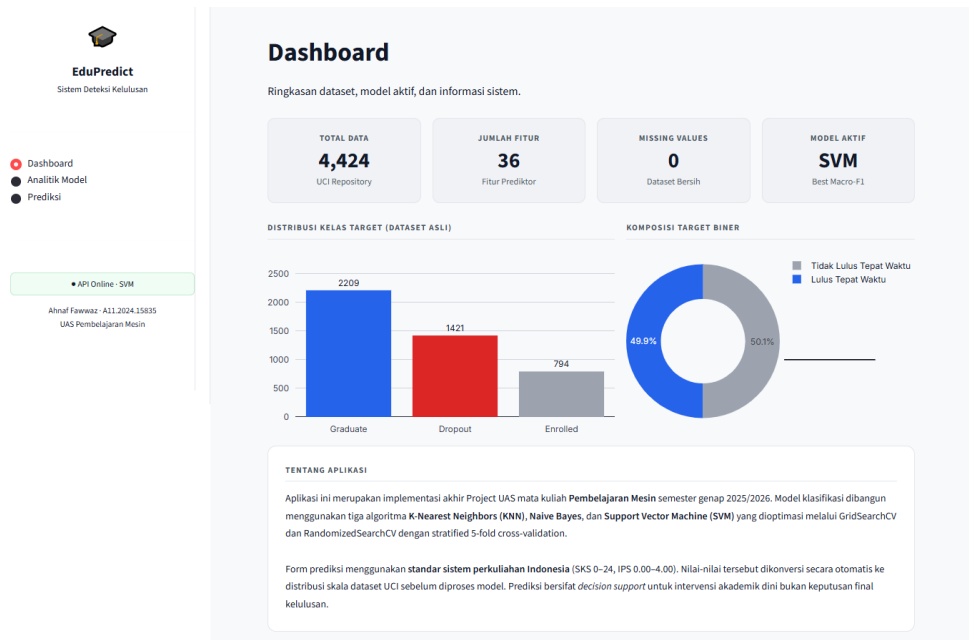
Tabel 8.2 Komponen File Utama EduPredict

File / Folder	Fungsi
app_streamlit.py	UI mode monolitik langsung memanggil model .joblib
app_streamlit_api.py	UI mode microservices terhubung ke FastAPI backend
api_fastapi.py	REST API backend: 4 endpoint + Swagger + CORS + Pydantic
src/ml_core.py	Fungsi reusable: load, preprocess, train, evaluate, optimasi
src/train.py	Pipeline pelatihan penuh ekspor model & laporan otomatis
src/predict.py	Inference dari model tersimpan
src/data_generator.py	Generator data dummy untuk pengujian endpoint
Dockerfile	Image tunggal: FastAPI (8000) + Streamlit (8501); HEALTHCHECK 30s
models/best_student_graduation_model.joblib	Model SVM terbaik siap production
reports/all_experiment_results.csv	Rekap performa seluruh eksperimen
reports/classification_reports.json	Laporan evaluasi detail per kelas
reports/audit_dataset.json	Profil data awal: baris, fitur, class balance
notebooks/graduation_optimization.ipynb	Notebook utama eksperimen — mencakup Soal 01 hingga 05
data/dataset_kelulusan.csv	File dataset UCI (separator: ;)
data/data_dictionary.md	Deskripsi detail tiap fitur dataset
models/scaler.joblib + feature_columns.joblib	Objek scaler dan urutan kolom fitur untuk konsistensi inference

8.2 Tampilan Aplikasi Streamlit


Streamlit menyediakan tiga halaman yang dirancang untuk kebutuhan berbeda. Gambar 8.1 hingga 8.3 di bawah ini menampilkan tangkapan layar aktual dari aplikasi EduPredict yang sudah di-deploy.

Halaman Dashboard. Menampilkan ringkasan sistem: total data (4.424 mahasiswa), jumlah fitur (36), missing values (0), dan model aktif (SVM). Dilengkapi bar chart distribusi kelas target asli (Graduate 2.209, Dropout 1.421, Enrolled 794) dan donut chart komposisi biner (49,9% vs 50,1%).



Gambar 8.1 Halaman Dashboard EduPredict

Halaman Analitik Model. Menampilkan tabel perbandingan performa seluruh model, bar chart Macro-F1 baseline vs optimized, dan radar chart multi-dimensi yang memperlihatkan profil Accuracy, Precision, Recall, dan Macro-F1 secara bersamaan untuk ketiga algoritma optimized.



Gambar 8.2 Halaman Analitik Model EduPredict

Halaman Prediksi. Form input disusun dalam empat expander: Data Akademik Semester 1 dan 2 (SKS Diambil dan IPS dalam skala Indonesia 0-4,0), Profil Pribadi (usia, status, jenis kelamin, waktu kuliah), Kondisi Finansial (status UKT, beasiswa, tunggakan), dan Data Orang Tua. Hasil ditampilkan sebagai gauge probabilitas beserta kartu analisis naratif berisi tiga faktor utama yang mendukung prediksi.



EduPredict
Sistem Deteksi Kelulusan

- Dashboard
- Analitik Model
- Prediksi**

API Online - SVM

Ahmad Fauzan - A11.2024.15835
UAS Pembelajaran Mesin

Prediksi Kelulusan

Isi data mahasiswa di bawah ini. SKS Lulus dihitung otomatis dari SKS Diambil dan IPS.

Data Akademik Semester 1

Isi berdasarkan KRS dan KHS semester pertama mahasiswa.

SKS Diambil

22

IPS

3,58

Pendidikan Sebelum Kuliah

SMA / SMK / Sederajat

Data Akademik Semester 2

Isi berdasarkan KRS dan KHS semester kedua mahasiswa.

SKS Diambil

20

IPS

3,01

SKS Lulus dan jumlah ujian dihitung dinamis dari SKS dan IPS.

Profil Pribadi

Usia Saat Masuk Kuliah

18

Status Pernikahan

Lajang

Kebutuhan Pendidikan Khusus

Tidak Ada

Jenis Kelamin

Perempuan

Waktu Kuliah

Reguler (Pagi/Siang)

Kondisi Finansial

Status UKT / SPP

Lunas / Tidak Ada Tunggakan

Status Beasiswa

Tidak Menerima

Riwayat Tunggakan / Utang

Tidak Ada

Data Orang Tua

IBU

Pendidikan Terakhir Ibu

SMP / Sederajat

Pekerjaan Ibu

Pekerja jasa & perdagangan

AYAH

Pendidikan Terakhir Ayah

SMP / Sederajat

Pekerjaan Ayah

Buruh / Pekerja kasar

Prediksi Kelulusan

HASIL PREDIKSI



80.7%

Probabilitas via SVM - FastAPI Backend

Lulus Tepat Waktu

Tingkat Keyakinan Model: 80.7%

Insight Profil Analisis:

- IPS rata-rata 3.29 kategori tinggi, mendukung kestabilan akademik.
- Seluruh 42 SKS berhasil diselesaikan tanpa beban mengulang.
- Status UKT dan kewajiban finansial tertib dan lancar.
- Aspek Prediksi mempertimbangkan seluruh atribut profil mahasiswa. Keputusan klasifikasi murni berasal dari pola dataset pelatihan.

RINGKASAN INPUT DATA

SKS Lulus Sem 1

22 SKS

IPS Sem 1

3,58

SKS Lulus Sem 2

20 SKS

IPS Sem 2

3,01

Status UKT

Lunas

Beasiswa

Tidak

Catatan Integrasi Sistem: Prediksi diproses oleh FastAPI backend menggunakan **SVM** model Machine Learning tanpa manipulasi paksa. Variabel makroekonomi menggunakan parameter baseline dataset untuk menjaga konsistensi ruang dimensi model. Sevelat decision support bukan keputusan akademik final.

Gambar 8.3 Halaman Prediksi dan Hasil EduPredict

8.3 REST API FastAPI

FastAPI menyediakan empat endpoint yang terdokumentasi secara otomatis. Seluruh request dan response divalidasi menggunakan Pydantic sehingga error input terdeteksi

sebelum sampai ke model. CORS dikonfigurasi untuk memungkinkan akses dari origin manapun, mendukung integrasi dengan SIAKAD eksternal.

Tabel 8.3 Endpoint REST API EduPredict

Method	Endpoint	Fungsi
GET	/	Informasi dasar sistem API
GET	/health	Health check untuk Docker HEALTHCHECK dan monitoring
GET	/model/info	Metadata model aktif: nama, jumlah fitur, kapabilitas
POST	/predict	Prediksi utama menerima data mahasiswa, mengembalikan prediksi + probabilitas


Endpoint POST /predict menerima data dalam format standar perkuliahan Indonesia (SKS 0-24, IPS 0,00-4,00) yang secara otomatis dikonversi ke skala dataset UCI Portugal di sisi server sebelum dikirim ke model. Respons mencakup label prediksi, probabilitas kelulusan, interpretasi naratif, nama model yang digunakan, dan catatan penggunaan.

Contoh response dari endpoint /predict ketika mahasiswa diprediksi Lulus Tepat Waktu:

```
{ "success": true, "prediction": 1, "label": "Lulus Tepat Waktu",  
  "metrics": { "probability_graduate_pct": 80.7, "probability_risk_pct": 19.3 },  
  "model_used": "SVM", "note": "Gunakan sebagai decision support." }
```

8.4 Dokumentasi API

FastAPI secara otomatis menghasilkan dua antarmuka dokumentasi yang dapat diakses melalui browser. Gambar 8.4 menampilkan Swagger UI (tersedia di /docs) yang menyediakan dokumentasi interaktif lengkap dengan kemampuan eksekusi request langsung dari browser. Gambar 8.5 menampilkan ReDoc (tersedia di /redoc) yang memberikan tampilan dokumentasi yang lebih terstruktur dan mudah dibaca. Kedua antarmuka ini memudahkan developer lain atau tim IT kampus untuk memahami dan mengintegrasikan API tanpa memerlukan dokumentasi tambahan.



Edit ValueSchema

```
{
  "beasiswa": "Tidak Menerima",
  "gender": "Laki-laki",
  "kebutuhan": "Tidak Ada",
  "kerja_ayah": "Buruh / Pekerja kasar",
  "kerja_ibu": "Tidak bekerja / Tidak diketahui",
  "pend_ayah": "SMA / SMK / Sederajat",
  "pend_ibu": "SMA / SMK / Sederajat",
  "s1_ips": 3.58,
  "s1_prev_qual": "SMA / SMK / Sederajat",
  "s1_sks_ambil": 22,
  "s2_ips": 3.01,
  "s2_sks_ambil": 20,
  "status_nikah": "Lajang",
  "tunggakan": "Tidak Ada",
  "ukt_lunas": "Lunas / Tidak Ada Tunggakan",
  "usia": 18,
  "waktu_kuliah": "Reguler (Pagi/Siang)"
}
```

ExecuteClear

Responses

Curl

```
curl -X 'POST' \
  'http://localhost:8000/predict' \
  -H 'accept: application/json' \
  -H 'Content-Type: application/json' \
  -d '{
    "beasiswa": "Tidak Menerima",
    "gender": "Laki-laki",
    "kebutuhan": "Tidak Ada",
    "kerja_ayah": "Buruh / Pekerja kasar",
    "kerja_ibu": "Tidak bekerja / Tidak diketahui",
    "pend_ayah": "SMA / SMK / Sederajat",
    "pend_ibu": "SMA / SMK / Sederajat",
    "s1_ips": 3.58,
    "s1_prev_qual": "SMA / SMK / Sederajat",
    "s1_sks_ambil": 22,
    "s2_ips": 3.01,
    "s2_sks_ambil": 20,
    "status_nikah": "Lajang",
    "tunggakan": "Tidak Ada",
    "ukt_lunas": "Lunas / Tidak Ada Tunggakan",
    "usia": 18,
    "waktu_kuliah": "Reguler (Pagi/Siang)"
  }'
```

Request URL

http://localhost:8000/predict

Server response

CodeDetails

200

Response body

```
{
  "success": true,
  "prediction": 1,
  "label": "Status Tepat Waktu",
  "interpretation": "Model mendeteksi pola akademik yang mendukung kelulusan tepat waktu.",
  "metrics": {
    "probability_graduate_pct": 77.61,
    "probability_risk_pct": 22.39
  },
  "model_used": "SWM",
  "note": "Hasil prediksi murni dari algoritma ML tanpa intervensi manual. Gunakan sebagai decision support, bukan keputusan final akademik."
}
```

Response headers

```
access-control-allow-credentials: true
access-control-allow-origin: http://localhost:8000
content-length: 379
content-type: application/json
date: Sun, 09 Jul 2023 17:12:03 GMT
server: uvicorn
vary: Origin
```

Responses

Code	Description	Links
200	Successful Response Media type application/json Controls Accept header. Example ValueSchema <pre>{ "success": true, "prediction": 0, "label": "string", "interpretation": "string", "metrics": { "probability_graduate_pct": 0, "probability_risk_pct": 0 }, "model_used": "string", "note": "string" }</pre>	No links
422	Validation Error Media type application/json Example ValueSchema <pre>{ "detail": [{ "loc": ["string", 0], "msg": "string", "type": "string", "input": "string", "ctx": {} }] }</pre>	No links

Gambar 8.4 Swagger UI EduPredict API (/docs)

8.5 Cara Menjalankan Sistem

Sistem dapat dijalankan dalam tiga cara sesuai kebutuhan. Pertama, mode monolitik yang paling sederhana cukup dengan menjalankan `python src/train.py` untuk melatih model, kemudian `streamlit run app_streamlit.py` untuk mengaktifkan antarmuka web. Semua proses berjalan dalam satu proses tanpa dependensi eksternal.

Kedua, mode microservices untuk skenario integrasi dengan sistem lain. Buka dua terminal secara paralel: terminal pertama menjalankan `uvicorn api_fastapi:app --reload --port 8000` untuk REST API backend, terminal kedua menjalankan `streamlit run app_streamlit_api.py` untuk UI frontend yang terhubung ke API. Setelah keduanya berjalan, aplikasi dapat diakses di `http://localhost:8501` dan dokumentasi API di `http://localhost:8000/docs`.

Ketiga, mode Docker untuk deployment yang portabel. Cukup jalankan `docker build -t edupredict`. diikuti `docker run -p 8000:8000 -p 8501:8501 edupredict`. Dockerfile yang disertakan mengemas kedua layanan dalam satu image dengan health check otomatis setiap 30 detik.

Live demo tersedia secara publik di <https://edupredict-ahnaf.streamlit.app>, dan seluruh kode sumber dapat diakses di <https://github.com/ahnafwzz/edupredict-early-warning-system>.

BAB 9 KESIMPULAN

9.1 Capaian Outcome

Project ini berhasil mencapai seluruh tujuan yang ditetapkan di awal. Tiga model machine learning (KNN, Naive Bayes, SVM) berhasil dibangun, dilatih, dan dievaluasi menggunakan pipeline yang konsisten dan reproducible pada dataset UCI dengan 4.424 sampel mahasiswa. SVM Baseline terbukti sebagai algoritma terkuat sekaligus dipilih sebagai model deployment dengan Macro-F1 tertinggi sebesar 82,07%. KNN Optimized mencatat peningkatan terbesar dari proses tuning (+4,26 pp dari 76,57% ke 80,83%), membuktikan bahwa systematic hyperparameter tuning memberikan nilai tambah nyata pada algoritma berbasis jarak.

Proses optimasi menggunakan GridSearchCV, RandomizedSearchCV, stratified k-fold CV, dan SelectKBest berhasil meningkatkan performa KNN secara signifikan (+4,26 pp), menjadi algoritma dengan peningkatan terbesar di antara ketiganya. Aplikasi web EduPredict dengan dua mode operasi (Monolitik dan Microservices), Streamlit frontend, dan FastAPI backend berhasil dikembangkan dan di-deploy sebagai sistem early warning yang dapat digunakan langsung oleh dosen wali, dilengkapi kontainerisasi Docker dan live demo di `https://edupredict-ahnaf.streamlit.app`.

Seluruh eksperimen dirancang untuk reproducibility penuh: `random_state=42` diterapkan konsisten di semua proses stokastik, `requirements.txt` mendokumentasikan versi seluruh dependensi, dan notebook Jupyter menyertakan output lengkap yang dapat diverifikasi ulang.

9.2 Keterbatasan

Meski project ini berhasil mencapai tujuannya, ada beberapa keterbatasan yang perlu diakui secara jujur. Pertama, dataset yang digunakan berasal dari satu institusi pendidikan di Portugal dengan karakteristik sistem pendidikan yang berbeda dari Indonesia. Generalisasi model ke konteks UDINUS atau perguruan tinggi Indonesia lainnya memerlukan validasi tambahan dengan data lokal yang relevan.

Kedua, fitur yang tersedia dalam dataset terbatas pada dimensi akademik, demografis, dan sosial-ekonomi yang terstruktur. Faktor-faktor seperti motivasi belajar, kualitas hubungan dengan dosen, keterlibatan dalam kegiatan kemahasiswaan, atau perubahan kondisi personal selama studi tidak tercakup dan berpotensi memiliki pengaruh signifikan terhadap kelulusan.

Ketiga, RandomizedSearchCV pada SVM dibatasi 20 iterasi untuk efisiensi komputasi. Eksplorasi yang lebih luas dengan lebih banyak iterasi atau pencarian berbasis Bayesian mungkin dapat menemukan konfigurasi SVM yang lebih optimal dan membalikkan tren penurunan performa yang diamati.

9.3 Rekomendasi Pengembangan

Untuk pengembangan lanjutan, tiga rekomendasi utama diusulkan. Pertama, integrasi Explainable AI menggunakan SHAP atau LIME untuk memberikan penjelasan tingkat individu pada setiap prediksi. Ini akan meningkatkan kepercayaan pengguna terhadap sistem dan membantu dosen wali memahami faktor spesifik yang mendorong prediksi risiko tertentu, bukan sekadar melihat skor numerik.

Kedua, eksplorasi algoritma ensemble seperti XGBoost atau Random Forest sebagai pembanding tambahan. Berdasarkan paper Al Hakim et al. (2026) yang mencapai akurasi 91,18% menggunakan XGBoost pada dataset yang serupa, ada potensi peningkatan performa yang signifikan jika algoritma ensemble ditambahkan ke dalam perbandingan.

Ketiga, inisiasi pengumpulan data internal UDINUS secara anonim untuk membangun model yang lebih relevan secara lokal. Kolaborasi dengan Biro Akademik untuk mengumpulkan data akademik historis mahasiswa (setelah melalui proses anonimisasi yang ketat) akan memungkinkan pembangunan model yang benar-benar mencerminkan karakteristik mahasiswa UDINUS.

DAFTAR PUSTAKA

- [1] M. F. Al Hakim et al., "Optimization of Machine Learning Model using Grid and Random Search Algorithms for Predicting Student Dropout," *Jurnal Teknik Informatika (JUTIF)*, vol. 7, no. 3, pp. 3012-3024, 2026, DOI: 10.52436/1.jutif.2026.7.3.5627.
- [2] A. Turkmenbayev et al., "Machine learning in predicting student performance in engineering programs," *Frontiers in Education*, vol. 10, 2025, DOI: 10.3389/feduc.2025.1562586.
- [3] A. Malik et al., "Advancing EDM through feature selection and classification techniques," *Scientific Reports*, vol. 15, 2025, DOI: 10.1038/s41598-025-92324-x.
- [4] R. Pelima et al., "Predicting university student graduation using academic performance and ML," *IEEE Access*, vol. 12, 2024, DOI: 10.1109/ACCESS.2024.3361479.
- [5] Setiawan et al., "Imbalanced Multi-class Prediction of Student Drop-out and Graduation," *ERIES Journal*, vol. 19, no. 1, 2026, DOI: 10.7160/eriesj.2026.190106.
- [6] A. Angeioplastis et al., "Predicting Student Performance and Enhancing Learning Outcomes," *Computers*, vol. 14, no. 3, 2025, DOI: 10.3390/computers14030083.
- [7] V. Villar and C. de Andrade, "Supervised ML algorithms for predicting dropout and academic success," *Discover Artificial Intelligence*, 2024, DOI: 10.1007/s44163-023-00079-z.
- [8] V. Realinho et al., "Predict Students Dropout and Academic Success," *UCI Machine Learning Repository*, 2022.